

Алгоритм поиска решений уравнения на словах с одной переменной

*Даниил Бидин
Алексей Угланов*

В статье представлен алгоритм, применяемый для поиска решений уравнения на словах с одной переменной, что является одной из задач семиотики. Работа алгоритма продемонстрирована на примерах. Практическая реализация алгоритма выполнена на языке программирования Python 3.

Ключевые слова: алгоритм, уравнения на словах, семиотика, поиск, префикс, суффикс.

One-variable word equations: algorithm of solution

*Daniil Bidin
Alexey Uglanov*

In this article we would like to introduce the algorithm developed and designed to find one-variable word equation solutions, which is one of the semiotics problems. Algorithm's work is demonstrated by examples. Practical implementation has been made by means of Python 3 programming language.

Key-words: algorithm, word equations, semiotics, search, prefix, suffix

Введение

Проблема поиска заданного слова в тексте является основой любого поискового алгоритма. Первые алгоритмы поиска появились в 60-70 годах прошлого века, и с тех пор их применение и усовершенствование не теряет своей актуальности. В настоящее время научному обществу требуются так называемые «быстрые» алгоритмы, т.е. алгоритмы с маленькой сложностью (увеличение объёмов информации для обработки не влечёт за собой экспоненциальный рост времени работы программы). Эта необходимость связана с проблемой поиска информации в условиях многократного увеличения мировых объёмов информации, отсутствии структурированности около 80% из них, а также информационным шумом. Одной из областей науки, требующей подобный алгоритм, является задача по решению уравнения на словах.

Эта задача является двойственной следующей задаче: «является ли некоторое подмножество слов кодом?» Опишем алгоритм решения уравнения на словах с одной переменной и продемонстрируем его работу.

Вводные определения и постановка задачи

Пусть $\Pi = \{a_1, a_2, \dots, a_n\}$ – конечный алфавит постоянных, т.е. букв. Длиной слова называется количество букв (символов) в нем. Обозначим длину слова Y как $|Y|$. Слово, в котором нет ни одного символа, называется пустым, оно имеет длину, равную 0 , и обозначается λ . Два слова называют равными в лексикографическом смысле тогда и только тогда, когда они состоят из одинаковых букв, записанных в одном и том же порядке. Это обозначается как $A \equiv B$. Конкатенацией AB (операцией приписывания) слов A и B называется слово, полученное в результате приписывания первого слова ко второму. Слово A называется подсловом слова D тогда и только тогда, когда существуют такие слова B и C , что конкатенация $BAC \equiv D$. Степенью слова C называется слово D вида C^n . Слово C , в свою очередь, является корнем слова D , если существует число n такое, что $C^n \equiv D$. Кодом называется множество слов $B = \{b_1, b_2, \dots, b_n\}$ в алфавите $\Pi = \{a_1, a_2, \dots, a_n\}$, если не существует такой перестановки символов $\{i_1, i_2, \dots, i_k\}$, что $b_{i_1}, b_{i_2}, \dots, b_{i_k} \equiv b_{j_1}, b_{j_2}, \dots, b_{j_e}$.

Уравнение на словах – совокупность букв алфавита и неизвестных переменных, являющихся словами, составленными из букв данного алфавита. Решением уравнения является такое слово, которое при подстановке в исходное уравнение даёт лексикографическое равенство двух частей уравнения. Общим решением уравнения называется множество всех решений уравнения.

Алгоритм позволяет найти множество общих префиксов и суффиксов слова UV , возникающего при конкатенации префикса U и суффикса V слов L или R (L и R – соответственно левая и правая части данного уравнения; условия выбора U и V указаны ниже).

Результат поиска входит в формулу

$$X = (Z_1 Z_2)^k Z_1 \quad (1)$$

являющуюся универсальной формулой решения уравнений на словах с одним неизвестным (формула выведена Ю.И. Хмелевским, им же доказано существование описываемого нами алгоритма [1]; доказательство сложности алгоритма и поиск общего решения были выполнены в работе М.Н. Максименко [2]) при следующих условиях:

1. одинаковое количество вхождений неизвестного в левую и правую части данного уравнения на словах (далее – д.у.);
2. нетривиальность д.у. (левая и правая части д.у. – не пустые слова);
3. несократимость д.у. (первые буквы левой и правой части д.у. не совпадают);

Уравнения на словах несократимого типа могут быть представлены в двух видах:

$$u_1 x u_2 x \dots u_n x \equiv x v_1 x v_2 \dots x v_m \quad (2)$$

$$u_1 x u_2 x \dots u_n x u_n \equiv x v_1 x v_2 \dots x v_m \quad (3)$$

4. непротиворечивость д.у. (первые или последние буквы левой и правой части совпадают и не принадлежат алфавиту Π).

Слово U является префиксом L или R , заканчивающимся до первого вхождения неизвестного X в соответствующую часть д.у. Слово V в случае (2) является суффиксом R или L , начинающимся после последнего вхождения неизвестного X в соответствующую часть д.у. В случае (3) слово V является суффиксом L или R .

Алгоритм применяется к строке, являющейся конкатенацией UV . До конкатенации каждое из слов сокращается до своего минимального по длине корня, если такой имеется. Z_1 и Z_2 – непересекающиеся суффикс и префикс UV , при которых слова U и V удовлетворяют условию сопряженности ($UV \equiv VU$).

В своей работе М.Н. Максименко предполагает, что для поиска Z_1 и Z_2 необходимо использовать алгоритм Кнута-Морриса-Пратта (далее – КМП) для поиска подстроки в строке [3]. При попытке воспользоваться алгоритмом КМП мы пришли к выводу, что использование его классической реализации нецелесообразно для данной прикладной задачи. Алгоритм, предложенный нами, сравнивает первые n символов (префикс) UV с последними n символами (суффикс) UV для целых значений n от 1 до длины слова UV за вычетом единицы, т.к. само слово UV не должно входить в множество решений.

Получившееся в результате обработки алгоритма множество значений является множеством предполагаемых значений Z_1 и Z_2 . Необходима проверка каждого предполагаемого значения не только на соответствие вышеуказанному условию, но и на получение лексикографического равенства при подстановке конечной формулы (1) в диофантово уравнение. В нашем случае формулу необходимо проверить для множества целых значений k от 0 до 2 включительно, т.к. дальнейшие действия нецелесообразны [1]. Значения X , удовлетворившие всем вышеперечисленным условиям, являются решениями данного уравнения на словах.

Работа алгоритма на примере уравнения на словах

Дано уравнение $aabbbxbbaabbbx = xbbxbbaabbbbaab$, удовлетворяющее условиям нетривиальности, несократимости, непротиворечивости.

1. Левая часть $L = aabbbxbbaabbbx$, правая часть $R = xbbxbbaabbbbaab$.
2. Слово $U = aabbb$ – префикс слова L до первого вхождения X ; а слово $V = bbaabbbbaab$ – суффикс слова R после последнего вхождения X .
3. Слово V – это вторая степень слова $bbaab$, т.е., $bbaab$ – корень V , следовательно, присвоим $V = bbaab$.
4. Конкатенация $UV = aabbbbbaab$. Найдём множество всех префиксов этого слова, одновременно являющихся его же суффиксами. После всех итераций получим множество предполагаемых значений Z_1 или Z_2 , равное $\{aab\}$.
5. Рассмотрим слово U . За значение $Z_2 = bb$ примем оставшийся после подстановки префикса $Z_2 = aab$ суффикс.
6. Рассмотрим слово V . Так как конкатенация $Z_1Z_2 \equiv V$, значит, данные значения Z_1 и Z_2 можно проверять при подстановке в формулу (1): $X = (Z_1Z_2)^kZ_1$.
7. При $k = 0$ после подстановки $X = aab$ в начальное уравнение, получим лексикографическое равенство двух частей, следовательно, $X_1 = aab$ является решением. Аналогично для $k = 1$ и $k = 2$ получаем $X_2 = aabbbbaab$ и $X_3 = aabbbbaabbbbaab$.
8. Итоговые значения X_1, X_2, X_3 – частные решения данного уравнения на словах, что и требовалось найти.

Заключение

Если уравнение на словах с одной переменной имеет решение, то объединение алфавитов $\Pi_1 \cup \{X\}$ не является кодом, где Π_1 – алфавит, состоящий из подслов левой и правой частей д.у. между вхождениями X .

В дальнейшем мы планируем рассмотреть проблему поиска решений усложнённых уравнений (введение новых переменных или усложнение структуры существующих уравнений) и поиска зависимостей данных уравнений с диофантовыми уравнениями и их решениями.

Список литературы

1. Хмелевский, Ю.И. "Уравнения в свободной полугруппе" / Ю.И. Хмелевский // Тр. МИАН СССР, 107 – М., 1971. – С.3-288.
2. Максименко М. Н. "Общее решение уравнения на словах с одной переменной" / М. Н. Максименко // Научные Труды Вольного экономического общества России: 4-я Междунар. науч. - практ. конф. им. А. И. Китова "Математические методы и информационные технологии в экономике и управлении" РЭУ им. Г. В. Плеханова 27-28 марта 2014 г., 186 / Вольное экон. о-во России, Рос. экон. ун-т им. Г.В. Плеханова. – М., 2014. – С. 88-93.
3. Максименко М. Н. "О коротких решениях уравнения на словах с одной переменной" // Труды Междунар. науч. конф. 28/IX – 2/X 2015г. "Образование, наука и экономика в ВУЗах и школах. Интеграция в международное образовательное пространство", 1 – Горис, Армения, 2015.

Код УДК

519.765 Математическая лингвистика. Общие вопросы. Математические исследования языков, имеющие общий характер.

Приложение 1. Практическое применение. Реализация на языке программирования Python 3.6

- https://github.com/oogl/0004_reu_discrete_maths_word_equations
или
- <https://ideone.com/TaIPQ7>